

# 会记

## 实时会议记录、翻译与行动闭环

让会议从“有人记录”变为“可实时理解、可复盘、可执行”。

| 项目   | 产品定义                                   |
|------|----------------------------------------|
| 产品形态 | Windows 本地优先的实时会议工作台                   |
| 正式支持 | 中文、英文、德文；英文/德文实时或会后翻译为简体中文             |
| 处理边界 | 音频、ASR、翻译、说话人分离默认本地；积墨负责纪要与 To-do-list |
| 本文口径 | 产品规格口径；容量、质量和成本指标区分已配置参数、稳定运行范围和压测指标   |

**一句话定位** 一套本地优先的实时会议系统：录音中提供低延迟多语言转写和流式草稿；停录后自动完成高精度 ASR 精修、说话人重排和最终翻译，完成后由用户点击按钮生成纪要，并自动生成 To-do-list。前端以浅色 AI 工作台呈现会议历史、录音控制、实时逐句稿、纪要、To-do-list 和文件下载；会议级参数支持普通/高级分级、滑块与数字输入联动以及预设模板。录音保存与后台后处理相互独立，任何后处理失败都不影响已保存的音频和快速转写。

## 产品一览

| 实时理解                                   | 会后可信                               | 本地优先                               | 可恢复                      |
|----------------------------------------|------------------------------------|------------------------------------|--------------------------|
| large-v3-turbo +<br>WebSocket 持续输出局部结果 | large-v3 精修 +<br>Resemblyzer 说话人重排 | ASR、翻译、Resemblyzer<br>说话人重排默认在本机运行 | 阶段检查点、修订事件、<br>失败重试与重启恢复 |

### 1. 产品定位与目标用户

会记面向需要“边开会边理解、会后快速复盘并形成执行清单”的团队。产品不是单纯的录音机或字幕组件，而是一条从音频采集到行动闭环的本地化处理链：实时阶段优先保证可用和低延迟，会后阶段再用更高质量的模型补齐准确率、说话人和结构化结果。

典型场景

- 跨语言项目会议：中文、英文、德文混合讨论，实时查看原文，英文/德文同步补充中文译文。
- 研发评审与项目例会：保留决策、条件、风险、阻塞和原文时间范围，减少会后手工整理。
- 访谈、销售与客户沟通：按发言人和时间轴复盘，输出会议纪要和可追踪的 To-do-list。
- 对隐私敏感的本地会议：音频和模型推理留在部署侧，仅在配置积墨后把纪要所需文本发送给外部服务。

产品承诺

| 用户价值  | 产品表现                                                                                      |
|-------|-------------------------------------------------------------------------------------------|
| 实时可见  | 不需要等整场会议结束才看到结果；通过 WebSocket 持续更新转写、语言和翻译状态。                                              |
| 保存优先  | 停录后先完成音频、快速转写和 manifest 落盘，再异步进行 ASR 精修、说话人重排和最终翻译；三项完成后才开放 “生成纪要和 To-do-list”按钮。         |
| 结果可追溯 | TranscriptStore、transcript_events.jsonl、修订号、模型元数据和 speaker_segments.json 共同支撑结果审计与前端原地更新。 |
| 故障可恢复 | 后处理按阶段写入检查点；应用重启会把 running 任务重新排队，从最近完成阶段继续。                                              |

2. 核心特点与特色能力

2.1 实时转写与翻译：先让会议可理解

实时链路统一使用 large-v3-turbo，默认 beam\_size=5、best\_of=5；录音中可在中文、英文、德文之间设置语言锁定：单选强制 ASR 语言，多选限制语言检测范围；锁定状态会持久化，并应用于停止后的 ASR 精修。实时短片段会复用上一句语言先验和最近最多 3 句上下文（最多 500 字符），遇到低质量结果时清除这些先验并自动重试，降低模型切换和隐式回退带来的不确定性。浏览器通过 AudioWorklet 采集 16 kHz、单声道 PCM16 音频，FastAPI WebSocket 接收并将 draft、partial/final 结果推送到前端。draft 采用服务端实际返回的完整快照持续替换识别中气泡，不模拟逐字打字；最终 utterance 生成后清理对应草稿。中文原文直接显示，英文和德文进入本地 OPUS-MT 翻译队列后在对应消息下方补充简体中文翻译。

**体验重点** 实时链路的目标不是在每个瞬间给出最终答案，而是持续给出可用的中间结果；最终质量由停录后的精修和说话人重排完成。

## 2.2 录音已保存与后台后处理彻底解耦

这是产品体验的关键设计。录音状态 `recording_state` 只表示录音和快速结果是否已经落盘；`postprocess` 独立展示 ASR 精修、说话人重排、翻译、纪要和 To-do-list 的阶段状态；前三项自动执行，纪要由用户按钮触发，成功后自动生成 To-do-list。用户可以在录音已保存后立即查看和下载，后台任务即使排队、失败或需要重试，也不会让会议停留在无限期的“正在保存”。

## 2.3 会后精修与说话人重排

停录后自动按固定顺序执行：`large-v3 ASR 精修` → `Resemblyzer 声纹嵌入、能量 VAD 与余弦相似度聚类` → 将说话人时间段与转写句子按重叠比例对齐 → 使用最终文本批量翻译。自动阶段全部完成后，用户点击按钮生成积墨纪要；纪要原子保存成功后自动生成 To-do-list。实时阶段仅显示匿名“演讲人 1/2/...”，会后按照首次出现顺序稳定编号并原地更新。暂不做实名声纹录入和参与者身份绑定。

## 2.4 版本化结果，而不是覆盖式写文件

精修可能改变句子数量、边界和说话人标签。系统通过稳定的 `source_segment_id`、`revision`、删除/替换事件和兼容旧字段的 `Utterance` 结构，避免旧句子残留在前端；历史会议仍可读取 `transcript.json`、`transcript.jsonl`、`meeting_transcript.md`、`translated_zh.md` 和 `manifest.json`。

## 2.5 模型状态透明，失败不伪装

启动预检会检查 ASR、VAD、OPUS-MT 和 `Resemblyzer` 包及本地 `pretrained.pt` 权重。必需能力未准备好时，健康状态保持 `loading/error` 并禁止新建会议。翻译状态明确区分 `pending`、`ready`、`not_needed`、`unsupported`、`failed`；ASR 失败记录模型信息、错误和重试，不把错误结果静默伪装成成功。

## 2.6 AI 工作台与用户参数控制

前端采用浅色 AI 工作台布局，保留会议历史、录音控制、实时逐句稿、后台处理、会议纪要、To-do-list、文件下载和设置入口等完整模块。中间区域是主要阅读焦点，右侧以轻量结果卡片呈现纪要和行动项，桌面端保持三栏结构，中等宽度和移动端按内容顺序降级为双列或单列。

1. 实时逐句稿：服务端 `draft` 增量直接更新底部“正在识别”气泡；收到 `utterance` 后清理对应草稿并插入正式消息。每条消息保留说话人、时间和语言元信息，原文与中文翻译上下叠放；中文原文不重复显示翻译，英文和德文在 `translation_update` 到达后只更新对应翻译气泡。语言

锁定通过 `language_lock` / `language_lock_ack` 同步到前后端：单选强制 ASR 语言，多选限制检测候选范围。

2. 会议成果流式化：会议纪要通过 `summary_reset`、`summary_delta`、`summary_complete` 和 `summary_failed` 事件持续更新；生成中显示状态和流式光标，完成后支持 Markdown 下载，失败时保留已提交内容并提供重试。To-do-list 继续支持重试和 JSON 下载，后台处理阶段条保持可见。
3. 用户参数控制：设置分为普通设置和高级设置。普通设置覆盖输入设备、本地音量预览、背景声过滤、语音起始、前置缓冲、静音结束、最短语音、语音比例、最长连续语音和实时刷新间隔；高级设置覆盖录音分段、实时/会后 `beam size`、`best_of`、重试质量阈值、翻译解码和说话人聚类参数，并提供精修、后台处理、说话人重排和录音保留开关。滑块右侧数字输入框与滑块双向联动，带单位参数显式显示单位。
4. 参数模板与边界：内置“均衡实时”“低延迟速记”“高质量会议”三套预设；选择模板会覆盖当前未保存参数，手动调整任一参数后自动标记为“自定义模板”。模板只覆盖当前会议的识别和处理参数，不覆盖模型名称、计算设备、模型下载策略或积墨纪要/To-do 接口等服务级配置。

接口边界：本次前端能力沿用现有 HTTP/WebSocket 协议和 `language_lock`、`language_lock_ack`、`draft`、`utterance`、`translation_update`、`summary_delta`、`postprocess_update` 等事件，不新增会议数据结构或后端持久化格式。

### 3. 从一次会议到行动闭环

产品流程围绕“先保存、后完善、用户可控”设计：新建会议后可从参数模板开始，也可以在普通/高级设置中逐项微调；录音开始后会议级识别参数默认锁定；语言锁定可在录音中调整，并同步影响后续实时识别和停止后的 ASR 精修，服务级模型、设备和积墨接口仍由部署侧管理。

5. 会前预检与参数选择：确认 `large-v3-turbo`、`large-v3`、`OPUS-MT`、`VAD` 和 `Resemblyzer` 权重已准备；新建会议后可选择“均衡实时”“低延迟速记”或“高质量会议”模板，必要时手动微调为“自定义模板”；未就绪时阻止新建会议。
6. 录音中：采集音频并按 30 分钟滚动切片保存；实时 ASR 以 `draft` 气泡持续更新逐句稿，最终 `utterance` 替换为正式原文消息，在线聚类提供匿名演讲人，英文和德文按批次异步补充中文翻译。

7. 停录瞬间：设置 recording\_state=finalizing，刷新音频和快速 ASR 队列，写入音频清单与 manifest，随后立即置为 recording\_state=complete 并广播 recording\_complete。
8. 后台后处理：postprocess 自动执行精修 ASR、Resemblyzer 说话人重排、对齐和最终翻译；阶段条持续展示当前阶段和进度，全部完成后进入 ready\_for\_summary。用户点击按钮触发会议纪要，纪要成功后自动触发 To-do-list；每一阶段写入持久化检查点。
9. 结果交付：前端接收 postprocess\_update 和单调递增的 snapshot\_revision，原地更新原文、译文、说话人和下载文件；summary\_delta 到达时持续追加会议纪要并显示生成中状态，完成或失败时保留结果并展示下载、重试入口。

## 状态模型

| 状态对象                      | 状态值                                                                  | 用户理解                      |
|---------------------------|----------------------------------------------------------------------|---------------------------|
| recording_state           | starting / recording / finalizing / complete / error                 | 录音与快速结果是否已经保存             |
| postprocess.state         | queued / running / ready_for_summary / complete / partial / error    | 后台精修、重排、翻译和生成任务的总体状态      |
| postprocess.current_stage | asr_refine / diarization(Resemblyzer) / translation / summary / todo | 当前正在处理的阶段                 |
| snapshot_revision         | 单调递增整数                                                               | 前端拒绝旧 snapshot，避免旧消息覆盖新状态 |

## 4. 产品优势与适用边界

### 相比“只做实时字幕”，优势在会后可信

- 实时与最终结果分层：用 turbo 换取实时性，用 large-v3 换取会后精度，用 Resemblyzer 完成无外部授权的匿名说话人重排。
- 结果不是一次性覆盖：修订事件让前端和导出文件知道“什么被改了”，适合审阅、回溯和后续质量评估。
- 失败有边界：模型缺失、翻译不支持、积墨超时和后处理异常都有明确状态；录音文件和快速转写仍然可用。
- 本地优先降低数据外发和 API 依赖：核心音频理解链无需把原始音频上传到第三方，也不会为本地 ASR、翻译和 Resemblyzer 说话人重排消耗远程 token。

产品边界

**需要如实说明** 正式支持三种语言，翻译方向固定为 en→zh、de→zh；语言锁定支持 zh/en/de，单选强制识别语言，多选限定检测范围；实时阶段的说话人是匿名编号而非实名身份；会议级识别参数默认仅在录音开始前可修改，语言锁定是可在录音中调整的例外；服务级模型、计算设备、下载策略和积墨接口需要通过部署配置调整并重启服务。默认部署以单活跃会议、单 GPU worker 为稳定基线。更大规模并发、多路音频输入、更多语言和实名声纹属于独立扩展能力。

5. 与竞品的区别

竞品对比以中国国内主流办公与会议产品为主：钉钉、企业微信、腾讯会议和飞书。它们优势在会议平台、组织通讯录、协作和云端服务；会记的差异在于本地优先的音频理解链、可控模型和会后结果修订。成本比较优先采用私有化、专属部署或混合云公开案例，不再拿普通 SaaS 月费直接横向比较。以下仅比较公开产品能力与公开采购信息，具体功能和价格受版本、套餐、地区、企业规模、定制范围和合同条款影响。

| 比较维度    | 会记                                                     | 国内会议/协作平台                                                                 | 主要差异                           |
|---------|--------------------------------------------------------|---------------------------------------------------------------------------|--------------------------------|
| 产品形态    | 独立的本地会议理解工作台：采集、转写、翻译、说话人、纪要和待办                        | 钉钉/企业微信/飞书：办公协作平台；腾讯会议：会议平台与会议资产                                          | 竞品强在组织协作与会议生态；会记专注音频理解链和结果可追溯  |
| 数据与部署   | ASR、翻译、Resemblyzer 说话人重排默认本地；仅将纪要/待办文本发送到积墨            | 以云端会议、云录制、云端 AI 和组织权限为主；部分企业版支持更强的管理/混合云能力                                | 会记适合内网/敏感会议；竞品适合快速开通、统一管理和跨端协作 |
| 实时转写/翻译 | 实时中文/英文/德文转写；英文、德文本地译为简体中文                             | 腾讯会议支持实时字幕/转写与中英互译，企业版本语言更广；钉钉会议支持实时字幕与多语言翻译；飞书支持实时转写/翻译；企业微信持续完善字幕、转写和同传 | 会记语言范围更聚焦，但推理链与数据边界可控          |
| 纪要与待办   | 停录后自动完成“精修→说话人重排→翻译”，用户按钮触发积墨纪要，成功后自动生成 To-do；阶段可见、可重试 | 普遍提供智能纪要、章节、重点、发言人和待办，并可与文档/任务/群聊联动                                       | 竞品协作分发更强；会记更强调原文、修订和阶段检查点      |
| 说话人能力   | 实时匿名编号；会后 Resemblyzer 重排；支持重叠片段元数据                     | 腾讯会议/飞书等支持发言人视图或声纹/身份关联；企业微信也提供转写/纪要能力                                    | 会记默认不做实名声纹绑定，减少隐私和身份误识别风险      |
| 集成与组织   | REST/WebSocket/API 文件下载；当前                             | 钉钉、企业微信、飞书接入组                                                             | 会记需通过企业版扩展层补齐                  |



| 比较维度      | 会记                                                                                                                                  | 国内会议/协作平台                                                                        | 主要差异                                                                          |
|-----------|-------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
|           | 以单机/内网为主                                                                                                                            | 织通讯录、日历、文档、任务和消息；腾讯会议提供开放平台 API                                                  | SSO、对象存储、队列和协作集成                                                              |
| 成本结构与使用成本 | 本地 ASR、翻译和 Resemblyzer 说话人重排不产生远程 token；积墨按调用计费：0.03 元/会话，2 次会话/API 请求，即 0.06 元/请求。以 N 个转写块估算，无重试约 (N+2)×0.06 元，另计 GPU/服务器、存储、实施和运维 | 私有化/专属版通常按项目报价，公开案例从约 25 万元/年到百万元级，可能包含软件授权、部署、定制、存储、运维、组织协同和容灾；腾讯会议完整混合云方案需商务询价 | 会记应与竞品三年 TCO 比较：会记外部调用成本透明，但需要承担本地基础设施；竞品交付范围更大、采购金额更高，不能把单个合同清单项直接理解成完整私有化价格 |

**产品判断** 会记最适合作为“本地会议理解层”或企业内网会议记录服务；它不试图替代钉钉、企业微信、腾讯会议和飞书的会议与组织协作平台能力，而是补足敏感会议场景中的本地音频理解、会后精修和结果可追溯。

私有化/专属部署成本参考

由于会记是本地部署产品，真正可比的不是竞品公开 SaaS 月费，而是私有化、专属部署或混合云方案的三年总拥有成本（TCO）。下表整理公开采购预算、中标结果、项目投资清单和官方部署说明。金额可能包含授权、部署、定制、存储、运维、组织协同、硬件适配或容灾，不等于单纯软件许可；因此只作为报价锚点，不作为统一官方价。

| 竞品   | 公开私有化/专属部署案例                                                                                                | 金额口径                          | 对会记的参考                                                     |
|------|-------------------------------------------------------------------------------------------------------------|-------------------------------|------------------------------------------------------------|
| 钉钉   | 浙江工业大学“2026 工大专属版钉钉”：预算 25.0 万元/年，最终中标 24.9 万元；重庆市公开清单另列中国烟草重庆公司“专属钉服务”投资 145 万元，含基础底座、专属安全、专属存储、专属打包和运营运维。 | 约 25 万/年；大型专属项目 145 万         | 小规模专属版可用约 25 万元/年作低位锚点；含平台底座、安全、存储和运维的项目应按百万元级另估。          |
| 企业微信 | 广东省机场管理集团：2 万用户、1 年私有化授权，含客户端定制打包和平台运维服务；项目限价 198 万元。                                                       | 198 万/年限价；约 99 元/用户/年（含定制运维）  | 说明大型组织私有化授权与定制运维的采购上限；不能把 99 元/用户/年当作单纯软件许可单价。             |
| 腾讯会议 | 官方支持企业混合云/专网会议，媒体业务可部署在客户私有环境，并支持信创、虚拟化、物理机和私有云；未公开统一私有化报价。                                                 | 商务询价                          | 报价时应单列本地媒体节点、专网/公网双轨、云上热备、SDK/API、硬件兼容、容灾和运维；标准版月费不作私有化报价。 |
| 飞书   | 上海期货交易所 2026—2029 年数字化协同平台成交 1047.7146 万元；清单单独列“飞书企业旗舰版_数据私有化”1680 元、“飞书 AI 企业版”99000 元。                    | 全平台 1047.7 万/3 年；私有化行项 1680 元 | 完整平台合同不能拆成会记可比的本地部署价格；1680 元只是合同清单单项，不能理解为完整私有化授权。         |

本表价格来源链接：

钉钉专属版采购预算（浙江工业大学）：[查看官方页面](#) 公开预算 25 万元/年，履约期 1 年。

钉钉专属版中标结果（浙江工业大学）：[查看官方页面](#) 公开中标价 24.9 万元。

专属钉服务投资清单（重庆市江北区）：[查看官方页面](#) 公开投资金额 145 万元，含基础底座、专属安全、专属存储、专属打包和运营运维。

企业微信私有化授权采购公告（广东省机场集团）：[查看官方页面](#) 公开项目限价 198 万元，范围为 2 万用户 1 年授权、定制打包和平台运维。

腾讯会议官方混合云部署说明：[查看官方页面](#) 用于官方支持混合云、专网会议和媒体下沉的能力依据；官方未公开统一私有化报价。

飞书平台采购合同公告（上海期货交易所）：[查看官方页面](#) 公开 2026—2029 年全平台成交金额及数据私有化、AI 企业版的合同清单金额。

**成本判断** 会记不应与竞品 SaaS 月费比较，而应与竞品私有化/专属部署的三年 TCO 比较。公开案例显示，国内协同平台的专属/私有化项目可能从约 25 万元/年到百万元级，往往包含授权、部署、定制、存储、运维和组织协同；腾讯会议完整方案需商务询价。会记则把本地音频理解能力单独交付，外部调用成本可按积墨精确拆分，但需要单独计入 GPU/服务器、存储、实施、运维和积墨调用。以 15,000 字符、约 3 个转写块、无重试为例，积墨费用约 0.30 元。

## 竞品优势与我们的取舍

| 视角     | 说明                                                          |
|--------|-------------------------------------------------------------|
| 竞品强项   | 组织通讯录、日历、会议室、文档/任务/群聊联动、跨端体验和云端运维；腾讯会议还具备原生会议上下文。           |
| 会记选择   | 先把本地音频理解、三语闭环、后处理可靠性和结果版本化做深，再通过 API、对象存储、队列和 SSO 逐步扩展企业能力。 |
| 不做虚假承诺 | 不把模型卡的 99 语言能力写成产品正式支持语言，不把架构上的可扩展性写成当前单机的并发承诺。             |



6. 技术架构概览

**数据流**
浏览器音频 → FastAPI REST/WebSocket → 有界队列与 GPU 资源锁 → 实时 ASR/精修 ASR/OPUS-MT/Resemblyzer 引擎 → TranscriptStore 与 manifest → 积墨纪要/To-do → 前端增量更新与文件下载

| 层级     | 核心组件                                                                        | 职责                                                           |
|--------|-----------------------------------------------------------------------------|--------------------------------------------------------------|
| 采集与交互  | Chrome/Edge、AudioWorklet、PCM16 16 kHz mono、WebSocket                        | 采集麦克风、发送有序音频包、接收 partial/final、断线自动重连                        |
| 服务层    | Python 3.11、FastAPI、Starlette、Uvicorn                                       | REST API、WebSocket gateway、健康检查、metrics、静态前端和鉴权票据            |
| 实时推理   | RealtimeAsrEngine; large-v3-turbo; VAD/分段; 在线 speaker clustering            | 以低延迟持续输出原文和匿名演讲人                                             |
| 会后推理   | RefinementAsrEngine; large-v3; DiarizationEngine; Resemblyzer voice encoder | 精修文本、匿名说话人分离、时间段对齐和修订事件                                      |
| 本地翻译   | TranslationEngine; OPUS-MT en→zh/de→zh; CTranslate2; SentencePiece          | 批量翻译、模型预检、缓存、状态区分和失败可见                                       |
| 资源调度   | GpuResourceManager; asyncio.Queue; checkpoint                               | 实时 ASR、精修 ASR、翻译和 Resemblyzer 共用 GPU 锁，严格串行，避免 8 GB 显存下的 OOM |
| 结果存储   | TranscriptStore; JSON/JSONL; transcript_events; speaker_segments; manifest  | 兼容旧文件，保存修订、模型、阶段状态和完整音频清单                                    |
| 外部智能生成 | 积墨 SSE; summary 与 todo 两个节点                                                 | 基于最终文本生成中文会议纪要和结构化 To-do-list; 支持重试与状态恢复                     |

7. 技术栈选择：为什么这样选

| 技术决策                         | 选择理由                                                                 | 相对其他方案的取舍                                               |
|------------------------------|----------------------------------------------------------------------|---------------------------------------------------------|
| Python 3.11                  | ASR、CTranslate2、Resemblyzer、音频与数据处理生态完整；asyncio 适合 IO、队列和 WebSocket。 | Node/Go 更适合纯网关，但模型编排和音频科学计算需要跨进程/跨语言；当前阶段 Python 减少集成面。 |
| FastAPI + WebSocket          | 同一服务承载 REST、WebSocket、健康检查和静态前端；异步接口天然适配实时事件。                        | 单纯 REST 轮询会增加状态延迟和请求量；独立消息网关虽可扩展，但当前产品的单机部署复杂度更高。       |
| faster-whisper / CTranslate2 | Whisper 生态成熟；CTranslate2 支持                                          | 相比远程 ASR API，减少音频外发、网络抖动                                |

| 技术决策                      | 选择理由                                                  | 相对其他方案的取舍                                                                         |
|---------------------------|-------------------------------------------------------|-----------------------------------------------------------------------------------|
|                           | GPU/CPU、量化和批量推理，适合本地部署。                               | 和按量 token；相比单一超大模型，便于实时/精修两阶段调度。                                                  |
| large-v3-turbo + large-v3 | turbo 的解码层更少，适合实时；large-v3 只在停录后精修，兼顾延迟、准确度和 8 GB 显存。 | 全程 large-v3 质量潜力更高但实时和显存压力更大；全程 turbo 体验快但会后质量上限较低。                               |
| OPUS-MT + CTranslate2     | 翻译方向固定、可本地运行、可批处理与缓存，远程 token 成本为零。                   | LLM 翻译更灵活但成本、延迟和输出一致性更难控制；OPUS-MT 的产品范围聚焦 en/de→zh。                               |
| Resemblyzer voice encoder | 本地声纹嵌入模型，配合能量 VAD 和在线余弦聚类完成匿名说话人分段；不需要外部授权或运行时下载。     | 不提供专门的重叠语音检测模型；重叠片段按时间对齐保留 speaker_ids 和 speaker_overlap 元数据，质量边界需要 DER/JER 语料评测。 |
| 版本化 TranscriptStore       | 精修会改变句子边界；事件、修订号和 source_segment_id 能让前端正确删除/替换旧结果。   | 直接多线程覆盖 transcript.jsonl 实现快但会产生竞态、旧句残留和难以审计的问题。                                  |
| 单 GPU 锁 + 有界队列            | 优先保证稳定、可预测和可恢复；队列满时可以明确拒绝或排队。                         | 并行加载会提高吞吐，但在 8 GB 显存基线下更易 OOM；企业版再按 GPU worker 横向扩展。                              |
| 积墨 SSE                    | 保留现有会议纪要和 To-do 能力，流式输出体验较好；本地端不再绑定一套通用 LLM。          | 带来外部服务依赖和按会话计费，因此需要在 metrics 中记录 API 请求数、会话次数、费用、耗时、失败和重试。                        |

## 8. 容量、并发与性能口径

**阅读说明** 本节把“当前可写入产品规格的事实”和“必须基于 benchmark 才能承诺的数值”分开。模型卡、配置项和架构设计可以说明能力边界，但不能替代目标 GPU、混合语言语料和 30 分钟连续录音下的压测。

| 指标      | 当前产品口径                                                                                                             | 状态    | 验收/说明                                                                                                            |
|---------|--------------------------------------------------------------------------------------------------------------------|-------|------------------------------------------------------------------------------------------------------------------|
| 正式支持语言  | 3 种：中文、英文、德文                                                                                                       | 产品规格  | 中文原文；英文/德文翻译为简体中文；不把 Whisper 99 语言模型卡当成产品正式支持范围。                                                                 |
| 输入音频    | 16 kHz、单声道、PCM16；浏览器 AudioWorklet；音频包上限 256 KiB                                                                    | 已配置   | 服务端按包大小和顺序校验；默认本地保存 FLAC（无 ffmpeg 时 WAV）。                                                                        |
| 分段与实时输出 | 预滚动 240 ms；开始说话判定 80 ms；静音结束 700 ms；最短有效语音 450 ms；partial 间隔 900 ms；单段上限 8 s                                       | 已配置   | 这些是分段/推送参数，不等于端到端 P95 延迟；需以 benchmark 结果发布延迟指标。                                                                  |
| 声音重叠    | 在线阶段：重叠片段只保留主说话人，不做实时双人并行转写；会后阶段：保留 speaker_ids，单个句子最多记录 10 个重叠说话人；speaker_overlap 上限 1.0，speaker_confidence 为 0-1 | 产品限制  | Resemblyzer 本身不提供专门重叠检测；按时间重叠比例 $\geq 15\%$ 的说话人进入 speaker_ids。多人同时说话越多，WER/说话人错误率越可能下降。10 人是存储/接口保护上限，不是识别质量保证。 |
| 匿名演讲人数量 | 实时匿名编号建议上限 10 人；会后 Resemblyzer 重排单场会议建议上限 20 人；接口/前端最多展示 32 个匿名演讲人                                                 | 产品规格  | 超过展示上限时按“其他演讲人”聚合或转入人工校正；匿名编号不等于实名身份，首次出现顺序编号。                                                                   |
| 单场会议时长  | 建议连续录音 $\leq 4$ 小时；音频每 30 分钟滚动切片；后处理时长随音频长度近似线性增长                                                                  | 运营建议  | 超过 4 小时建议拆分会议或按阶段停录，避免单任务积压。                                                                                     |
| 单实例活跃会议 | 默认 1 场；MEETING_MAX_ACTIVE_MEETINGS=1                                                                               | 部署基线  | 单 GPU 本地部署。增加到多场前需按 GPU worker 横向扩展并重新压测。                                                                        |
| GPU 资源锁 | 实时 ASR、large-v3、翻译和 Resemblyzer 共用 1 把进程内 GPU 锁，严格串行                                                               | 已实现   | 避免 8 GB 显存同时执行重推理；当前不提供可配置 worker pool 或显存硬配额。                                                                   |
| 有界队列    | 实时推理 64；精修 16                                                                                                      | 已配置   | 两条音频处理队列有界；企业任务队列属于扩展能力。                                                                                         |
| 多人并发    | 当前稳定基线：1 路活跃会议；企业压测目标：10 路同时会议                                                                                     | 基线/目标 | 10 路是压测目标，不是单 GPU 承诺；需要目标 GPU、中英德混合语料和 30 分钟连续                                                                   |

| 指标     | 当前产品口径                                                                | 状态   | 验收/说明                                           |
|--------|-----------------------------------------------------------------------|------|-------------------------------------------------|
|        |                                                                       |      | 录音验收。                                           |
| 断线恢复   | WebSocket 断线恢复窗口 15 s；<br>stream ticket TTL 60 s；WebSocket 认证超时 5 s   | 已配置  | 窗口内恢复不会结束会议；前端通过 snapshot_revision 丢弃旧消息。       |
| 音频保留   | 完整会议结果默认保留 30 天；<br>MEETING_KEEP_AUDIO=0 时，音频在精修和说话人重排成功后删除；失败时保留以便重试 | 已配置  | retention_days=0 可关闭自动过期删除；受磁盘容量、企业合规和删除策略影响。   |
| 质量指标   | WER、CER、语言识别准确率、BLEU、chrF、DER、JER、首结果延迟、分段延迟、RTF、P50/P95、峰值显存         | 验收指标 | 需要固定语料和 benchmark 才能给出具体数值。                     |
| GPU 基线 | RTX 5060 Laptop 8 GB / 32 GB RAM；重任务串行执行                              | 部署基线 | 当前未实施显存硬配额；更换 GPU 需重选 CUDA/PyTorch wheel 并重新压测。 |

模型、参数与部署清单

以下数据以 2026-08-14 本机实际模型文件、代码常量和模型配置为准。参数量表示模型复杂度，磁盘大小表示当前量化/转换格式的本机占用，两者不能互相替代；不同平台、量化方式和缓存版本会造成文件大小差异。

| 阶段        | 实际模型/实现                                                                               | 关键参数                                                                                                                                                                                                            | 当前本机大小/状态                                                   |
|-----------|---------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|
| 实时 ASR    | faster-whisper；mobiuslabsgmbh/faster-whisper-large-v3-turbo（large-v3-turbo，约 809M 参数） | WhisperModel；CUDA 时 int8_float16，CPU 时 int8；transcribe 默认 beam_size=5、best_of=5、vad_filter=False、condition_on_previous_text=False；短片段可传入上一句语言先验和最近最多 3 句、最多 500 字符的 initial_prompt；低质量结果会清除先验并自动重试；录音期间常驻，停止后释放 | 当前 CTranslate2 快照 1,621,665,983 B（1.51 GiB）；已缓存             |
| 会后 ASR 精修 | faster-whisper；Systran/faster-whisper-large-v3（large-v3，约 1,550M 参数）                  | CUDA 时 int8_float16、CPU 时 int8；transcribe beam_size=6、best_of=5、vad_filter=False、condition_on_previous_text=False；停录保存后按需加载；与其他 GPU 阶段串行                                                                        | 当前 CTranslate2 快照 3,090,835,702 B（2.88 GiB）；已缓存             |
| VAD/实时分段  | FunASR AutoModel；funasr/fsmn-vad（FSMN，428,738 参数）                                     | 16 kHz；80 维 Mel，LFR 后输入维 400；4 层 FSMN；linear 250、projection 128；项目分段参数：预滚动 240 ms、开始 80 ms、静音结束 700 ms、最短有效语音 450 ms、partial                                                                                    | 模型权重 model.pt 1,721,366 B（1.64 MiB）；完整本机 snapshot 4,024,535 |

| 阶段        | 实际模型/实现                                                                                  | 关键参数                                                                                                                                                                  | 当前本机大小/状态                                                            |
|-----------|------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------|
|           |                                                                                          | 900 ms、单段上限 8 s                                                                                                                                                       | B (3.84 MiB) ; ready                                                 |
| 语言识别      | Whisper 返回 language + language_probability 为主；文本规则与可选 Lingua 为后备                         | ASR 语言置信度 ≥0.65 时优先采信；上一句语言会作为短片段 language 先验；缺失/低置信度才进入中文字符、英德规则和 Lingua；低质量结果自动清除先验重试；语言锁定支持单选强制、多选限制；正式范围 zh/en/de                                                 | 无独立语言大模型；置信度和 language_source 写入 Utterance                           |
| 说话人重排     | Resemblyzer voice encoder；本地 pretrained.pt；能量 VAD + embedding + cosine online clustering | 约 1,423,616 参数；16 kHz mono；能量帧 30 ms；最大静音间隔 250 ms；最短语音 350 ms；embedding context 1.6 s；hop 0.8 s；cluster threshold 0.68；重叠映射阈值 15%；匿名 speaker_1/...；无专门 overlap model | 17,090,379 B (16.30 MiB) ；权重预检已就绪；运行时按需加载；唯一说话人实现，无授权、无运行时下载、无回退     |
| 本地翻译      | Marian OPUS-MT → CTranslate2 int8；en→zh 77,943,296 参数；de→zh 76,363,776 参数                | 两者均为 d_model=512、encoder 6 层、decoder 6 层；CUDA int8_float16 / CPU int8；beam_size=2、max_decoding_length=384、repetition_penalty=1.05；SentencePiece                       | en→zh 82,552,022 B (78.73 MiB) ；de→zh 80,656,414 B (76.92 MiB) ；均已就绪 |
| 纪要与 To-do | Jimo SSE 外部服务；两个 share 节点分别承担 summary、todo                                               | 客户端固定发送 messages、sessionId、source=api、extra={}；不在客户端注入 model/temperature；Authorization 仅服务端环境变量；总结按状态分块，To-do 读取已保存纪要                                                 | 外部模型名、temperature 由 Jimo 节点配置，不由当前代码实际注入；文档不把 README 示例当成客户端运行时事实    |

本机必需本地模型合计约 4.56 GiB（按当前快照和项目转换目录求和，不含重复/旧缓存、Python/CUDA 依赖和积墨外部模型）。其中 Whisper 两套 ASR 约占 4.39 GiB，是主要磁盘占用。

当前 HF refs/main：turbo=0a363e9161cbc7ed1431c9597a8ceaf0c4f78fcf；large-v3=edaa852ec7e145841d8ffdb056a99866b5f0a478。

部署环境（已核对）：Windows 11 x64；AMD Ryzen AI 7 H 350（8 核 16 线程）；31.12 GiB RAM；RTX 5060 Laptop GPU 8,151 MiB，驱动 610.88；CUDA 12.8 / PyTorch 2.11.0+cu128；Python 3.11.14。默认 MEETING\_DEVICE=auto、单活跃会议；GPU 重任务由单进程资源锁串行执行。

部署资源配置建议

下表按当前单机架构给出部署口径。“已验证基线”是本机实际跑通环境；“最低可运行”只表示能够安装和执行，不代表实时延迟达标；生产发布前仍需使用目标机器和真实中英德混合音频做 30 分钟连续压测。

| 资源     | 最低可运行（不承诺实时）                                            | 推荐单机生产基线                                                              | 已验证本机 / 说明                                                           |
|--------|---------------------------------------------------------|-----------------------------------------------------------------------|----------------------------------------------------------------------|
| CPU    | x64，至少 4 核 8 线程；CPU 模式可运行，但 large-v3 精修和本地翻译耗时可能明显增加    | 8 核 16 线程或以上；GPU 推理时 CPU 仍负责 WebSocket、音频编解码、分段、文件与任务调度               | AMD Ryzen AI 7 H 350，8 核 16 线程；单活跃会议                                 |
| 系统内存   | 16 GB；仅适合单会议、低并发和受控测试，需避免同时加载额外模型或大批量任务                 | 32 GB；为两套 Whisper、Python/CUDA 运行时、音频缓存和后处理留出余量                        | 31.12 GiB 可用物理内存；当前单会议基线                                             |
| GPU    | 可不配 GPU，使用 CPU int8；功能可运行但不承诺实时体验                       | NVIDIA CUDA GPU，8 GB 显存或以上；驱动、CUDA 与 PyTorch wheel 必须匹配               | RTX 5060 Laptop GPU；CUDA 可用；单进程 GPU 资源锁串行调度                          |
| 显存     | CPU 模式为 0；若启用 CUDA，不建议低于 8 GB                           | 8 GB 级；实时模型停止后释放，再加载 large-v3 精修，避免两套 ASR 同驻留                         | 物理显存 8,151 MiB；当前代码未实现显存硬配额                                          |
| 磁盘     | 至少预留 15 GB 给程序、Python/CUDA 依赖和当前模型；录音/结果空间另计            | 建议预留 20 GB 以上系统盘空间，并为 result/meetings 单独规划容量或对象存储                     | 必需模型约 4.56 GiB；当前 .venv 约 5.41 GiB；项目内 OPUS-MT 约 155.65 MiB；旧缓存会额外占用 |
| 系统与运行时 | Windows 10/11 x64；Python 3.11；Chrome 或 Edge；FFmpeg 建议安装 | Windows 11 x64；Python 3.11；CUDA 12.8 对应 PyTorch/torchaudio；生产关闭模型自动下载 | Windows 11；Python 3.11.14；CUDA 12.8；PyTorch/torchaudio 2.11.0+cu128  |
| 单机并发   | 1 场；MEETING_MAX_ACTIVE_MEETINGS =1                      | 当前单进程基线 1 场。增加并发前必须压测；不能把 10 路目标理解为单张 8 GB GPU 的承诺                    | 默认 1 场活跃会议；实时与精修队列严格有界                                               |
| 网络     | 本地 ASR、VAD、翻译和说话人重排可离线；首次准备模型时需要下载                      | 生产预下载并校验所有模型；仅纪要 /To-do 使用积墨时需要访问外部 Jimo 节点                           | 生产建议<br>ASR_AUTODOWNLOAD=0、<br>TRANSLATION_AUTODOWNLOAD=0            |

**容量边界** 企业第一阶段可以把 10 路同时会议作为压测目标，但当前单机产品基线仍是 1 路。多路部署应拆分为多个 GPU worker，并使用目标 GPU 测量首结果延迟、P50/P95、RTF、峰值显存、队列深度和恢复时间后再确定安全流数。

9. 积墨调用成本与 Token 口径

会记的核心语音理解链是本地模型，因此 token 不是所有阶段的成本单位；积墨的“会话次数”才是外部纪要与待办调用的计费口径：

| 阶段     | 调用与 token 口径                                                                                |
|--------|---------------------------------------------------------------------------------------------|
| 本地 ASR | large-v3-turbo 实时识别和 large-v3 会后精修不调用远程 LLM API，不产生远程 API token；主要消耗 GPU 时间、显存、CPU/RAM 和磁盘。 |
| 本地翻译   | OPUS-MT en→zh、de→zh 通过 CTranslate2 本地批量翻译，不产生远程 API token；成                                 |



| 阶段            | 调用与 token 口径                                                                               |
|---------------|--------------------------------------------------------------------------------------------|
|               | 本主要是推理时间和模型存储。                                                                             |
| 本地说话人分离       | Resemblyzer voice encoder 使用本地 pretrained.pt, 不产生远程 API token; 必须将包和权重准备状态纳入健康检查。          |
| 积墨会议纪要        | 每一次积墨 API 请求消耗 2 次“会话次数”。积墨计费为 20 万次会话 6,000 元, 因此 1 次会话=0.03 元; 1 次 API 请求=2×0.03=0.06 元。 |
| 积墨 To-do-list | To-do 接口每次请求同样消耗 2 次会话次数, 即 0.06 元/请求; 如果自动重试, 每次重试再增加 0.06 元。                             |
| 总成本公式         | 积墨费用 = API 请求次数 × 0.06 元 = 会话次数 × 0.03 元; 会话次数 = API 请求次数 × 2。                             |

**估算公式** 20 万次会话=6,000 元 → 0.03 元/会话。每次 API 请求消耗 2 次会话 → 0.06 元/请求。一次会议的积墨费用 = (摘要 API 请求数 + To-do API 请求数 + 重试请求数) × 0.06 元。摘要按分块状态更新和最终生成执行, 若有 N 个转写块, 通常至少 N+1 次请求; To-do 通常 1 次, 因此无重试时约 (N+2) × 0.06 元。

以 15,000 字符的会议转写为例, N≈3: 摘要通常 4 次 API 请求, To-do 通常 1 次, 共 5 次请求、10 次会话, 积墨费用约 0.30 元; 若摘要状态压缩增加 1 次请求, 则约 0.36 元; 每次重试额外 0.06 元。Token 与积墨会话次数是两套口径: 会话次数用于积墨计费, token 用于模型输入/输出用量统计。若积墨响应没有返回 provider usage, 就不能从字符数精确反推 token; 生产 metrics 应记录 input\_tokens、output\_tokens、API 请求数、会话次数、重试次数和预计费用。

## 10. 可靠性、安全与兼容性

### 可靠性设计

- 模型缺失时前置阻断: 不让用户录完整场会议后才发现停录阶段无法精修。
- 后处理失败不影响录音: recording\_state 保持 complete, postprocess 标记 error/partial, 提供阶段级重试。
- 重启可恢复: running 任务自动变为 queued, 从最近完成的 checkpoint 继续。
- 断线可恢复: WebSocket 短暂断线保留 15 秒恢复窗口; 前端只接受不早于当前 snapshot\_revision 的状态。
- 指标可观测: /api/v2/health 和 /api/v2/metrics 暴露模型就绪、队列、耗时、失败、重试、OOM、模型回退、积墨 API 请求数、会话次数和预计费用等指标。

## 安全与数据边界

- 浏览器不接收积墨 URL 和 Authorization；密钥只在服务端环境变量中使用。
- 音频、ASR、翻译和 Resemblyzer 说话人重排默认本地运行；只有启用积墨后，纪要/To-do 所需文本才会发往外部服务。
- 本地结果保留 transcript.json、transcript.jsonl、manifest、事件日志和模型元数据，便于删除、审计和迁移。
- 生产企业部署仍需补充录音加密、访问审计、SSO/OIDC、对象存储生命周期和跨区域传输评估；这些属于企业部署扩展项。

## 兼容性

保留既有 /api/v2 API、WebSocket 事件、结果文件名和历史会议读取能力，并新增 /api/v2/health、/api/v2/metrics、postprocess\_update、postprocess 和 snapshot\_revision。旧 Utterance 没有新增字段时使用默认值直接读取。

11. 产品路线与下一步

| 阶段      | 目标                                      | 关键验收                                                                         |
|---------|-----------------------------------------|------------------------------------------------------------------------------|
| 正式产品能力  | 稳定运行实时转写、停录快速保存、会后精修、说话人重排、翻译、纪要和 To-do | 不再无限期“正在保存”；任务可重试、可恢复；旧会议可读取和下载。                                             |
| 质量评测与发布 | 建立固定中英德混合语料和可重复 benchmark               | WER/CER、语言识别、首结果/P50/P95、RTF、显存、BLEU/chrF、DER/JER 和 E2E 保存/后处理耗时。            |
| 企业扩展版   | 从单机本地 store/queue 扩展到可横向部署              | PostgreSQL 元数据、S3/MinIO 音频、Redis/RabbitMQ/NATS 队列、GPU worker pool、SSO、审计和配额。 |
| 能力扩展版   | 扩大语言和身份能力                               | 新增翻译方向、更多语言质量门槛；实名声纹必须经过用户授权、隐私评估和独立验收。                                      |

30 秒产品介绍话术

**对外介绍** 会记是一套本地优先的实时会议 AI 工作台，支持中文、英文和德文会议的实时转写与中译。左侧管理会议历史，中间通过流式逐句稿持续显示原文和中文翻译，右侧查看后台处理、会议纪要、To-do-list 和文件。用户可以在普通/高级设置中使用模板或滑块加数字输入微调会议参数；录音中还可按中文、英文或德文锁定识别范围；录音期间用轻量实时模型帮助参会者跟上讨论，停录后自动用更高质量 ASR 和说话人重排完成精修，会议纪要支持流式生成并自动生成 To-do-list。与单纯字幕或云端会议机器人不同，会记把录音保存、后台后处理和结果修订拆开，既保留本地数据边界，也让失败可见、任务可重试、结果可追溯。

12. 资料依据与口径说明

产品与技术参数依据本仓库的 README.md、DEPLOYMENT.md、pyproject.toml、realtime\_meeting/config.py、runtime.py、session.py、storage.py、realtime\_meeting/web/index.html、app.js、styles.css 和已实现的产品能力整理；前端模板、流式逐句稿和设置交互以 2026-08-14 版本为准。竞品与模型资料为公开官方页面，访问日期：2026-08-13。公开产品能力可能随版本、地区和套餐变化。

Whisper large-v3-turbo 模型卡: [查看官方页面](#) 用于模型能力、99 语言模型卡与 turbo/large-v3 解码层差异说明。

Resemblyzer 项目与 voice encoder: [查看官方页面](#) 用于本地 voice encoder、声纹 embedding 和 speaker verification/聚类实现口径；本项目按 16 kHz 单声道输入封装。

**CTranslate2 性能文档:** [查看官方页面](#) 用于量化、beam size 和本地翻译推理的技术依据。

**钉钉会议智能翻译与实时字幕:** [查看官方页面](#) 用于钉钉会议实时语音转文字、实时字幕和中英翻译能力的公开口径。

**钉钉 AI 听记:** [查看官方页面](#) 用于钉钉实时转写与智能总结的公开产品定位。

**腾讯会议实时字幕:** [查看官方页面](#) 用于实时字幕、自动识别和中英互译能力的公开说明。

**腾讯会议智能录制与 AI 纪要:** [查看官方页面](#) 用于章节、重点、发言人、纪要和待办等会后能力的公开说明。

**腾讯会议官方混合云部署:** [查看官方页面](#) 用于专网会议、媒体下沉、混合云和 TCO 口径；不作为统一私有化报价。

**企业微信 App Store 产品说明:** [查看官方页面](#) 用于企业微信智能纪要、实时字幕和同声传译等公开能力口径。

**飞书妙记产品页:** [查看官方页面](#) 用于飞书转写、AI 总结、章节、待办和协作能力的公开产品定位。